

# Conclusion

## 误差

误差类型

- 模型误差
- 观测误差
- 截断误差：算法不可能无限迭代，只能近似到一定程度
- 舍入误差：计算机表示的数位有限

## 绝对误差

$e(x) = x - x^*$  近似值和绝对值的差

绝对误差限

$$|e(x)| \leq \eta$$

## 有效数字

n 位有效数字 则相对误差限  $\delta \leq \frac{1}{2a_1} \times 10^{-(n-1)}$

相对误差限为  $\delta \leq \frac{1}{2(a_1+1)} \times 10^{-(n-1)}$  则有n位有效数字

## 求近似值

不动点迭代

### 1. 二分法

#### 1. 零点存在定理/存在唯一

##### 1. 验证连续性

##### 2. 零点存在与否

2. 终止条件  $|\frac{(b-a)}{2^{k+1}}| < \epsilon$  AKA  $k > \frac{\log(b-a) - \log \epsilon}{\log 2} - 1$

### 2. 不动点迭代

### 3. 牛顿迭代：一种特殊的不动点迭代法

#### 1. 验证二阶连续性 单根 $f''(x) \neq 0 \rightarrow$ 平方收敛

#### 2. m重根情况 构造 $f(x) = (x - x_0)^m g(x)$

3.  $x_{k+1} = x_k - m \frac{f(x)}{f'(x_k)}$

使用条件

1. 收敛条件： $|\varphi'(x)| \leq 1$
2. 收敛值
3. 停机
4. 初值

## 收敛定理

### 全局收敛

函数  $\varphi(x)$  满足

1.  $\forall x \in [a, b], \varphi(x) \in [a, b]$
2.  $\exists$  常数  $L$ , 使得  $\forall x \in [a, b]$ , 有  $|\varphi'(x)| \leq L < 1$

### 局部收敛

$x^*$  是方程  $x = \varphi(x)$  的根  $\varphi'(x)$  在  $x^*$  附近连续且  $|\varphi'(x)| < 1$

则迭代过程  $x_{k+1} = \varphi(x_k)$  在  $x^*$  附近具有局部收敛性

### 收敛速度

$$|\varphi'(x)| < |\varphi'(y)|$$

$\varphi(x)$  的收敛速度更快

### 收敛率

若存在常数  $p \geq 1$   $c \neq 0$  ( $p > 1, c \neq 0$ ) or ( $p = 1, c < 1$ ) 使得

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^p} = c$$

称为  $x_{k+1} = \varphi(x_k)$  是  $p$  阶收敛的

$p=1$   $c=1$  次线性收敛

设  $\varphi(x)$  在  $x = \varphi(x)$  的根  $x^*$  附近有连续  $p$  阶导数 则对于迭代过程  $x_{k+1} = \varphi(x_k)$

1.  $\varphi'(x^*) \neq 0$  线性收敛
2.  $\varphi'(x^*) = 0$   $\varphi''(x^*) \neq 0$  平方收敛
3.  $\varphi'(x^*) = \varphi''(x^*) = \dots = \varphi^{p-1}(x^*) = 0$   $\varphi^p(x^*) \neq 0$   $p$  阶收敛

$p$  越大 收敛越快

$p$  阶导数值越小 收敛越快

## 二分法

二分法事前估计

$$|x - x^*| \leq \frac{1}{2^{k+1}}(b - a)$$

## 不动点迭代

局部收敛定理:

$x^*$  是方程  $s = \varphi(x)$  的根

$s = \varphi'(x)$  在  $x^*$  附近连续且  $|\varphi'(x^*)| < 1$

则迭代  $x_{k+1} = \varphi(x_k)$  在  $x^*$  附近具有**局部收敛性**

## 牛顿迭代(切线法)

初值敏感

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

定义域单根 二阶导不为0 则局部收敛

牛顿迭代法的二阶收敛率为  $\frac{1}{2} |f''(x^*)/f'(x^*)|$

### 简化牛顿法

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_0)}$$

只计算初值导数

### 弦截法

取  $f'(x_k) \approx \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$

$$x_{k+1} = x_k - \frac{f(x_k)}{\frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}} \times (x_k - x_{k-1})$$

割线代替切线

### 牛顿下山法

扩大初值选取范围

$$x_{k+1} = x_k - \lambda \frac{f(x_k)}{f'(x_k)} \quad \lambda \in (0, 1]$$

$\lambda$  为下山因子

选取合适的下山因子 满足  $|f(x_k)| < |f(x_{k-1})|$

从  $2^{-n}$  数列中选取条件的

## 数值解法

## 范数

范数性质

1. 非负性
2. 齐次性
3. 满足三角不等式

$R^n$ 中不同范数等价

## 向量范数

依坐标收敛和依向量收敛等价

$$\lim_{k \rightarrow \infty} x^{(k)} = x^* \Leftrightarrow \lim_{k \rightarrow \infty} \|x^{(k)} - x^*\| = 0$$

## 矩阵范数

相容范数定义

相容性  $\|A \cdot B\| \leq \|A\| \cdot \|B\|$

算子范数的定义:  $\forall A \in R^{n \times n}$   $\|x\|$  是  $R^n$  中的向量范数

$$\|A\|_p = \sup_{x \in R^n, x \neq 0} \frac{\|Ax\|_p}{\|x\|_p}$$

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \quad \text{最大列和}$$

$$\|A\|_2 = \lambda_1 \quad A^T \cdot A \text{最大特征值}$$

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \quad \text{最大行和}$$

谱半径  $\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$

$\rho(A) \leq \|A\|$  成立

$$\rho(A) < 1 \Leftrightarrow \lim_{k \rightarrow \infty} A^k = 0$$

## Gauss消去法

消元+回代

列主元消去：每次消元后 把绝对值最大元素所在的行换上来

## LU分解

如果所有顺序主子式均不为零 则存在唯一分解式  $A = L \cdot D \cdot R$  单位下三角 $\times$ 非奇异对角 $\times$ 单位上三角

Doolittle分解	Crout分解	Cholesky分解
$A = L \cdot (DR) = L \cdot U$	$A = (LD) \cdot R = \tilde{L} \cdot \tilde{U}$	$A = L \cdot L^T$ (A对称 正定)

如果  $A = A^T$  则  $A = LDL^T$

计算过程

```
1 while n+1<len(A):
2     A[n+1:,n]/=A[n,n+1:]
3     A[n+1:,n+1:]-=A[n+1:,n]*A[n+1:,n+1:]
```

## 追赶法

求解过程稳定 只需要 $5n-4$ 次乘法

基于特定格式对于LU分解的结论

## 改进平方根

优化掉了开方

$$A = LDL^T$$

$$d_r = (a_{rr} - \sum_{k=1}^{r-1} l_{rk}^2 \cdot d_k) / l_{rr}$$
$$l_{jr} = (a_{rj} - \sum_{k=1}^{r-1} l_{rk} \cdot d_k \cdot l_{jk}) / d_r$$

## 迭代法

### Jacobi

$$A = D + N$$
$$Ax = b$$
$$(D + N)x = b$$
$$Dx = -Nx + b$$
$$x = -D^{-1}Nx + D^{-1}b$$
$$B_{Jacobi} = -D^{-1}N$$
$$g_{Jacobi} = D^{-1}b$$

## Gauss-Seidel

Jacobi迭代的基础上 每次迭代使用最新的值

$$\begin{aligned}A &= D + L + U \\ Dx^{k+1} &= -Lx^{k+1} - Ux^k + b \\ x^{k+1} &= -(D + L)^{-1}Ux^k + (D + L)^{-1}b\end{aligned}$$

## 收敛性

判断条件 依次

1.  $A$ 严格占优
2.  $\|B\| < 1$
3.  $\rho(B) < 1$

(基本定理)  $x = Bx + g$  收敛 等价于  $\rho(B) < 1$

都不满足 说明**不确定是否收敛**

## 插值

### 多项式插值

$$p_2(x) = a_0 + a_1x + a_2x^2$$

### 反插值法

构造反函数进行插值

### Lagrange 插值法

构造插值基函数  $l_i(x_j) = \delta_{ij} = (i == j)$

$$\begin{aligned}\omega(x) &= \prod_{j=0}^n (x - x_j) \\ l_i(x) &= \frac{\omega(x)}{(x - x_i)\omega'(x_i)}\end{aligned}$$

### 线性插值

$$L_1(x) = y_0l_0(x) + y_1l_1(x) = y_0\frac{x-x_1}{x_0-x_1} + y_1\frac{x-x_0}{x_1-x_0}$$

### 抛物线插值

$$L_2(x) = y_0l_0(x) + y_1l_1(x) + y_2l_2(x)$$

# Newton 插值法

减少增加数据时的计算开销

牛顿插值基函数组

$1, (x - x_0), \cdots, \prod_{i=0}^{n-1} (x - x_i)$

## 差商

- $f[x_i] = f_i$   $y = f(x)|_{x=x_i}$  的零阶差商
- $f[x_i, x_{i+1}] = \frac{f[x_{i+1}] - f[x_i]}{x_{i+1} - x_i}$   $y = f(x)$  在  $x_i, x_{i+1}$  处一阶差商
- $f[x_i, x_{i+1}, x_{i+2}] = \frac{f[x_{i+1}, x_{i+2}] - f[x_i, x_{i+1}]}{x_{i+2} - x_i}$  二阶差商

$$N_n(x) = N_{n-1} + f[x_0, x_1, \cdots, x_n] \prod_{j=0}^{n-1} (x - x_j)$$

## 插值余项

$R_n(x) = f(x) - p_n(x)$  为插值多项式的插值余项/误差

$$R_n(x) = f(x) - p_n(x) = \frac{f^{(n+1)}(\zeta)}{(n+1)!} \omega(x) \quad \zeta \in [a, b]$$

线性插值多项式余项	抛物线插值多项式余项
$R_1(x) = \frac{f''(\zeta)}{2!} (x - x_0)(x - x_1)$	$R_2(x) = \frac{f'''(\zeta)}{3!} (x - x_0)(x - x_1)(x - x_2)$

## Hermite插值

两个互异点通过微商值构造不超过3次的插值多项式

基函数	$x_0$	$x_1$	$x_0$	$x_1$
$h_0(x)$	1			
$h_1(x)$		1		
$H_0(x)$			1	
$H_1(x)$				1

$$H(x) = y_0 h_0(x) + y_1 h_1(x) + m_0 H_0(x) + m_1 H_1(x)$$

根据函数值和微商值 可假设  $h_0(x) = (a + bx)(x - x_1)^2$

$$\begin{aligned} h_0(x) &= (1 + 2l_1(x))l_0^2(x) \\ h_1(x) &= (1 + 2l_0(x))l_1^2(x) \end{aligned}$$

根据函数值和微商值 可假设  $H_0(x) = a(x - x_0)(x - x_1)^2$

$$\begin{aligned} H_0(x) &= (x - x_0)l_0^2(x) \\ H_1(x) &= (x - x_1)l_1^2(x) \end{aligned}$$

# 最小二乘法

拟合评价准则

- 残差最大绝对值  $\max_{1 \leq i \leq n} |e_i|$  最小
- 残差绝对值之和  $\sum_{i=1}^n |e_i|$  最小
- 残差平方和  $\sum_{i=1}^n e_i^2$  最小(最小二乘法)

$A^T A x = A^T b$  为  $Ax = b$  的法方程组或正则方程组(normal equation)

## 数据线性化

原函数	线性化	数据变动
$y = c_1 e^{c_2 t}$	$Y = \ln c_1 + c_2 t$	$(t_i, y_i) \Rightarrow (t_i, \ln y_i)$
$y = c_1 t^{c_2}$	$Y = \ln c_1 + c_2 \ln t$	$(t_i, y_i) \Rightarrow (\ln t_i, \ln y_i)$

# 数值积分

## 插值性求积公式

$$\int_a^b f(x) dx \approx \sum_{k=0}^n f(x_k) \cdot \int_a^b l_k(x) dx$$

误差  $-\frac{h^3}{12} f''(c)$

## 等距节点插值

$$\int_a^b f(x) dx \approx (b-a) \sum_{k=0}^n f(x_k) \cdot c_k^{(n)}$$

Newton-Cotes公式  $c_k^{(n)}$  为Newton-Cotes系数

## 梯形公式

$n=1 \quad c_0^{(1)} = c_1^{(1)} = \frac{1}{2}$

$$\int_a^b f(x) dx \approx T = (b-a) [\frac{1}{2} f(a) + \frac{1}{2} f(b)]$$

## Simpson公式

$n=2 \quad c_0^{(2)} = c_2^{(2)} = \frac{1}{6} \quad c_1^{(2)} = \frac{4}{6}$

$$\int_a^b f(x) dx \approx S = (b-a) [\frac{1}{6} f(a) + \frac{4}{6} f(\frac{a+b}{2}) + \frac{1}{6} f(b)]$$



## 代数精度

$$f(x) = x^i$$

满足  $\int_a^b f(x)dx = \sum_{k=0}^n f(x_k) \cdot A_k$  的最大  $i$  为代数精度次数

## 截断误差

方法与 **插值余项** 相同

$$R = \begin{cases} -\frac{(b-a)^3}{12} f''(\eta), & \text{梯形公式余项 } R_T \\ -\frac{1}{2880} (b-a)^5 f^{(4)}(\eta), & \text{Simpson余项 } R_S \end{cases}$$

## 复合求积

### 梯形公式

区间  $n$  等分

$$T_n = \frac{h}{2} [f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b)]$$

$$R_{T_n} = -\frac{b-a}{12} \cdot h^2 \cdot f''(\eta)$$

### Simpson

区间  $n$  等分后会取  $2n$  个值

即如果只有8个值 Simpson公式只能4等分 梯形公式可以8等分

$$S_n = \frac{h}{6} [f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + 4 \sum_{i=0}^{n-1} f(x_{i+1/2}) + f(b)]$$

$$R_{S_n} = -\frac{b-a}{2880} \cdot h^4 \cdot f^{(4)}(\eta)$$